

Observatorio CEIPA

Sistema integral de inteligencia de datos para la cadena de servicios petroleros de Vaca Muerta. Arquitectura, metodología, cronograma y esfuerzo.

DIRIGIDO A

Cámara Empresarial Industria Petrolera
y Afines del Neuquén

FECHA

20 de abril de 2026

VERSIÓN

1.0 · Borrador

— Índice

1	Resumen ejecutivo	p. 3
2	Contexto y problema	p. 5
3	Objetivos y alcance	p. 7
4	Arquitectura técnica	p. 9
5	Estrategia de datos y fuentes	p. 11
6	Modelo dimensional	p. 13
7	Metodología analítica	p. 15
8	Capa de presentación	p. 17
9	Calidad, testing y observabilidad	p. 19
10	Seguridad y gobernanza	p. 21
11	Cronograma y entregables	p. 23
12	Esfuerzo, equipo y sostenibilidad	p. 25
13	Riesgos y mitigación	p. 27
14	Conclusión	p. 29

01 Resumen ejecutivo

Propuesta de construcción del Observatorio CEIPA: un sistema integral de inteligencia de datos para la cadena de servicios petroleros de Vaca Muerta, diseñado para anticipar cambios de actividad, optimizar decisiones operativas y fortalecer la posición negociadora institucional de la Cámara.

Las pymes proveedoras del sector energético argentino operan en un contexto de alta volatilidad, presión sobre costos y baja previsibilidad de la demanda. A pesar de la abundancia de datos operativos, laborales y contractuales, la información está **fragmentada** y **subutilizada** para decisiones estratégicas. Esta propuesta plantea construir, en seis meses, una plataforma que consolide todas las fuentes públicas disponibles, las transforme en indicadores accionables y las entregue a través de un dashboard de clase profesional y reportes auto-generados.

FUENTES OFICIALES	SERIES DE DATOS	HORIZONTE DEL PROYECTO	FASES
20 +	590 K obs	6 meses	5 +1

1.1 Qué entregamos

- **Observatorio público** con 13 secciones analíticas, incluyendo un índice propio — *IAP-CEIPA* — que consolida en un solo número la demanda de servicios de estimulación hidráulica y logística.
- **Plataforma de datos reproducible** con pipeline de ingesta automatizado y warehouse analítico; cada dato mostrado es trazable a su fuente oficial.
- **Modelo predictivo a 12 meses** con tres escenarios (base, optimista, pesimista) y backtest documentado.
- **Mapa geoespacial interactivo** con 84.000+ pozos, permisos de exploración y sísmicas registradas.
- **Reportes mensuales automáticos** en PDF y exportación granular a CSV.
- **Capa privada de benchmarking** (fase 2) que permite a cada socio comparar sus indicadores contra el sector preservando la confidencialidad.

1.2 Valor diferencial

El equipo propuesto combina **ciencias sociales** (comprensión de dinámicas sectoriales, laborales e institucionales) y **desarrollo tecnológico** (plataformas de datos, modelos predictivos, diseño de producto). Esto nos permite no solo procesar datos sino *traducirlos en decisiones estratégicas concretas* adecuadas al perfil de la Cámara.

Qué NO es esta propuesta. *No es una consultora que entrega un reporte estático. No es un sistema cerrado que requiere dependencia perpetua del proveedor. Al finalizar las cinco fases, CEIPA posee el código fuente, la documentación metodológica completa y el know-how operativo para sostener el Observatorio con 1 analista part-time.*

02 Contexto y problema

Tres asimetrías estructurales definen el problema de información que enfrentan los proveedores del upstream argentino.

2.1 El problema real

Las empresas proveedoras de servicios petroleros en la cuenca Neuquina operan bajo **tres asimetrías** que el mercado no resuelve por sí solo:

1. **Asimetría vertical de información.** Las operadoras (YPF, Vista, Pampa Energía, Shell, Chevron, Tecpetrol, TotalEnergies) conocen su pipeline de inversión a 12-24 meses; los proveedores lo ven con 3-6 meses de rezago, cuando ya es tarde para planificar capacidad.
2. **Asimetría contractual.** Cadena de pagos de 60 a 120 días y poder de negociación desbalanceado por la concentración de demanda.
3. **Asimetría laboral-paritaria.** Los costos se negocian en bloque con Petroleros Privados (CCT 644/12) pero impactan diferencialmente según el perfil de cada empresa. La Cámara no cuenta con herramientas cuantitativas para simular escenarios en tiempo real durante la ronda.

2.2 Por qué ahora

Vaca Muerta atraviesa una fase de **consolidación acelerada**: longitud promedio de rama horizontal pasó de 1.200 m en 2014 a ~3.000 m en 2024, las inversiones anunciadas superan los USD 10.000M anuales y el país se prepara para ser exportador neto de gas. Simultáneamente, el ecosistema informacional argentino publica hoy — por primera vez — volúmenes de datos abiertos auditables suficientes para construir un observatorio riguroso sin necesidad de fuentes pagas.

La ventana de oportunidad combina: *disponibilidad de datos abiertos + necesidad institucional clara + madurez de tecnologías de datos + fase de crecimiento estructural del sector*. Postergar el proyecto significa dejar que cada empresa socia construya versiones parciales y fragmentadas de lo mismo, duplicando esfuerzo y sin poder de síntesis institucional.

2.3 Stakeholders

ACTOR	ROL	INTERÉS PRINCIPAL
Comisión Directiva CEIPA	Sponsor institucional	Posicionamiento ante medios, gobierno, operadoras
Empresas socias	Usuarios primarios	Anticipación de demanda, benchmarking, paritarias
Secretaría de Energía / Provincia Neuquén	Interlocutores	Visión consolidada del sector proveedor
Operadoras (YPF, Vista, etc.)	Contrapartes	Diálogo informado sobre capacidad instalada proveedora
Sindicato Petroleros Privados	Contraparte paritaria	Referencia cuantitativa compartida
Medios y academia	Difusores	Fuente autoritativa citable

03 Objetivos y alcance

Cuatro objetivos funcionales organizan el producto; un alcance deliberadamente acotado protege la entregabilidad.

3.1 Objetivos funcionales

1. **Anticipar** cambios de actividad con indicadores adelantados (sísmicas, permisos, etapas de fractura, DUC wells).
2. **Optimizar** decisiones operativas de socios vía benchmarking anónimo y comparación sectorial.
3. **Mejorar competitividad** con inteligencia laboral, análisis de costos y simuladores de escenarios paritarios.
4. **Fortalecer** la capacidad de negociación institucional de CEIPA ante operadoras, gobierno y sindicato con una fuente de datos única, reproducible y autoritativa.

3.2 Alcance

DENTRO DE ALCANCE

- Ingesta automatizada de al menos 20 fuentes públicas argentinas y 1 internacional (World Bank).
- Warehouse analítico en DuckDB con al menos 12 *marts* documentados.
- Dashboard con 13 secciones cubriendo: resumen, actividad, producción, GIS, empleo, precios, forecast, catálogo.
- Índice IAP-CEIPA construido, publicado mensualmente y metodológicamente documentado.
- Modelo predictivo SARIMAX + Prophet + XGBoost con tres escenarios y backtest.
- Reportes mensuales en PDF y export CSV por sección.
- Capa privada con autenticación y benchmarking anónimo para socios.
- Documentación completa, tests automatizados y traspaso a equipo CEIPA.

FUERA DE ALCANCE

- Fuentes pagas (Rystad, S&P Platts, Wood Mackenzie).
- Integraciones con sistemas contables o ERP de empresas socias.
- Compra y análisis de imágenes satelitales en fase inicial (considerado en roadmap 12m).
- Publicación de datos sensibles individuales de empresa (privacidad diferencial protege lo contrario).

04 Arquitectura técnica

Stack pragmático de bajo costo operativo, orientado a reproducibilidad y sostenibilidad a largo plazo con mínima dependencia del proveedor original.

4.1 Principios rectores

- **Código sobre configuración.** Todo lo que define el sistema — fuentes, transformaciones, paleta, indicadores — vive en Python/SQL versionado en git.
- **Reproducibilidad total.** Cualquier dato mostrado es regenerable desde cero con `python -m src.ingest`.
- **Bajo costo operativo.** Todo corre en un VPS de USD 20-40/mes o en infraestructura existente de CEIPA.
- **Dependencia mínima del proveedor.** Stack open-source estándar mantenible por cualquier Python developer con experiencia básica en datos.
- **Separación de capas.** Ingesta, warehouse, transformación y presentación son módulos independientes y testeables.

4.2 Vista general




FIG. 1 *Arquitectura lógica del Observatorio. Pipeline unidireccional fuentes → warehouse → presentación, con capa transversal de gobernanza y calidad. Los bloques punteados rojos indican capacidades de fase 2.*

4.3 Stack tecnológico

CAPA	TECNOLOGÍA	JUSTIFICACIÓN
Lenguaje principal	Python 3.12	Ecosistema de datos dominante; contrataciones sostenibles.
Ingesta HTTP	requests + urllib3	Librerías estándar; control fino de timeouts/reintentos.
Data manipulation	pandas + pyarrow	APIs conocidas; performance suficiente a este volumen.
Warehouse analítico	DuckDB	SQL OLAP embebido; zero-ops; misma performance que un cluster para <10GB.
Validación schemas	Pandera	Contratos tipados sobre DataFrames; tests declarativos.
Visualización	Plotly + pydeck	Charts interactivos + mapas 3D WebGL.
Frontend	Streamlit	Velocidad de iteración >> custom React para MVP; migrable en fase 2.
Modelos predictivos	statsmodels · Prophet · xgboost	Ensemble combina robustez estadística + captura de no-linealidades.
Export PDF	Playwright Chromium	Reusa el propio render HTML; sin WeasyPrint ni wkhtmltopdf.
Testing	pytest · Pandera	Smoke + schema + integration en un solo comando.
CI/CD	GitHub Actions	Cron diario para detectar drift de fuentes.
Orquestación	Prefect (fase 2)	Reintentos, lineage, UI. Innecesario en fase 1.

4.4 Infraestructura propuesta

Un **único VPS** (4 vCPU, 8 GB RAM, 80 GB SSD) alcanza para:

- Correr el dashboard Streamlit en producción.
- Ejecutar el pipeline de ingesta mensual (15-20 minutos).
- Alojar el warehouse DuckDB completo (~500 MB).
- Generar los reportes PDF on-demand.

Costo estimado: **USD 20-40/mes** (Hetzner / DigitalOcean / Contabo), más USD 10/mes en backups S3. **Certificado SSL** gratuito vía Let's Encrypt. **CDN** opcional con Cloudflare Free.

4.5 Estructura del código

```
ceipa_data/
├── src/
│   ├── sources.py           # Catálogo declarativo de fuentes
│   ├── ingest.py           # Pipeline de ingesta + construcción de marts
│   ├── forecast.py         # Modelos predictivos
│   └── dashboard/
│       ├── app.py          # Router (<50 líneas)
│       ├── shared.py       # Contexto compartido
│       ├── theme.py        # Sistema de diseño (paleta + componentes)
│       ├── export.py       # CSV + PDF
│       └── sections/       # 13 módulos, uno por página
├── tests/                  # pytest + Pandera
├── data/                   # DuckDB warehouse (git-ignored)
├── raw/                   # Archivos descargados (git-ignored)
└── docs/                  # Documentación técnica y metodológica
```

05 Estrategia de datos y fuentes

Una política explícita de selección, validación y cacheo de fuentes minimiza el riesgo de drift y maximiza la reproducibilidad del Observatorio.

5.1 Principios

- **Prioridad a fuentes oficiales argentinas** con obligación de publicación (Secretaría de Energía, BCRA, INDEC, Min. Trabajo). Son robustas ante cambios de gobierno porque tienen sustento normativo.
- **Acceso programático preferido** (APIs JSON/CSV) sobre scraping HTML. El costo de mantenimiento de scrapers es 10x mayor.
- **Catálogo declarativo**. Cada fuente es una entrada en `sources.py` con metadatos: URL, formato, frecuencia, notas metodológicas. Agregar una nueva fuente = agregar una entrada.
- **Tolerancia a fallos**. Reintentos automáticos, fallback a snapshots previos, alertas cuando una fuente lleva >48h sin actualizar.
- **Trazabilidad total**. Cada fila del warehouse guarda la fecha de carga y el nombre del archivo origen.

5.2 Catálogo de fuentes priorizadas

ORGANISMO	DATASETS	FRECUENCIA	ROL EN EL OBSERVATORIO
Secretaría de Energía (CKAN)	Producción pozos, fracturas, permisos, sísmicas, trayectorias, regalías, reservas, precios gas, canon, yacimientos (12+)	Mensual	Núcleo del Observatorio
BCRA API v4	TC mayorista/minorista, tasas, IPC, base monetaria (7 series)	Diario	Contexto macro
INDEC / SSPM	IPC, EMAE, empleo sectorial, índices salariales (12 series)	Mensual/trimestral	Empleo y precios
World Bank Pink Sheet	Commodities (Brent, WTI, Dubai, LNG, coal)	Mensual	Benchmarks internacionales
Boletín Oficial	Homologaciones CCT, resoluciones	Diaria	Simulador paritario (fase 2)
Carga privada socios	Facturación, días de cobro, dotación (encuesta mensual)	Mensual	Benchmarking anónimo (fase 2)

5.3 Pipeline de ingesta

El pipeline se ejecuta con un único comando y tiene las siguientes características:

1. **Descarga con caché incremental:** si la URL no cambió desde la última corrida (validado por ETag/Last-Modified), se salta.
2. **Validación de schema** vía Pandera antes de persistir: si el tipo o rango de una columna es inesperado, falla con alerta.
3. **Transformación SQL:** los *marts* se construyen como vistas DuckDB parametrizables, no tablas físicas — se regeneran en milisegundos.
4. **Logging estructurado:** cada corrida deja un registro auditable (fuente, filas, latencia, errores).
5. **Modo selectivo:** `python -m src.ingest --source produccion_no_convencional` permite iterar sin re-descargar todo el warehouse.

5.4 Política de calidad

- **Normalización de entidades:** tabla de mapeo `empresa_canonica` que unifica "YPF S.A.", "YPF SA", "Y.P.F." → "YPF S.A." con reglas documentadas y revisables.
- **Manejo explícito de nulls:** valores missing se marcan como `SIN_DATO` en dimensiones y como NULL en métricas numéricas; no se imputan por default.
- **Series nominales vs. reales:** todas las métricas monetarias se ofrecen en ambas presentaciones con deflactor IPC.
- **Versionado del warehouse:** snapshots mensuales del `ceipa.duckdb` se conservan en S3 por 24 meses.

06 Modelo dimensional

Arquitectura tipo medallion con tres capas lógicas: bronze (raw), silver (marts tipados) y gold (indicadores de negocio).

6.1 Capas

CAPA	PREFIJO	CONTENIDO	EJEMPLOS
Bronze	raw_*	Descargas crudas, mínima transformación (column names lowercased)	raw_produccion_no_convencional · raw_bcra · raw_fracturas_adjunto_iv
Silver	mart_*	Tipos corregidos, normalización de entidades, agregaciones por dimensión	mart_produccion_mensual · mart_pozos_geo · mart_macro
Gold	mart_iap_*	Indicadores construidos, artefactos analíticos finales	mart_iap_ceipa · mart_iap_forecast · mart_iap_backtest

6.2 Marts principales

MART	GRANO	DIMENSIONES	MÉTRICAS
mart_produccion_mensual	empresa × yacimiento × mes	cuenca, provincia, tipo pozo, tipo recurso	prod petróleo m³, prod gas Mm³, agua, pozos activos
mart_fracturas_mensual	empresa × cuenca × mes	tipo reservorio	pozos fracturados, etapas, arena nacional/importada, agua
mart_pozos_geo	pozo	lon/lat, cuenca, provincia, yacimiento	producción 12m, tipo reservorio, fecha terminación
mart_trayectorias	pozo terminado	mes terminación, tipo pozo	profundidad vertical, rama horizontal, total MD
mart_precios_gas	cuenca × mes × segmento	contrato	precio distribuidora, GNC, industria, usina, export, PPP
mart_macro	fecha × variable	fuelle (BCRA/INDEC)	valor
mart_iap_ceipa	mes	—	pozos fracturados, etapas, arena, IAP
mart_iap_forecast	mes futuro	—	base, optimista, pesimista

6.3 Convenciones

- **Claves primarias naturales** donde existen (idpozo, id_fractura); sintéticas solo si hacen falta.
- **Fechas siempre como DATE**; nunca strings.
- **Magnitudes físicas en unidades SI**: metros, metros cúbicos, toneladas.
- **Dimensiones categóricas en MAYÚSCULAS** para facilitar joins case-insensitive.
- **Columnas anexas opcionales** (geojson, observaciones) se mantienen pero no participan en agregaciones.

07 Metodología analítica

Cuatro pilares metodológicos sostienen la capa analítica: el índice IAP-CEIPA, los escenarios predictivos, el simulador paritario y el benchmarking privado con privacidad diferencial.

7.1 Índice de Actividad Proveedora (IAP-CEIPA)

El IAP-CEIPA es un índice mensual que sintetiza la demanda de servicios especializados (set de fracturas, logística, arena) en un solo número comparable en el tiempo.

FÓRMULA

$$IAP_t = 100 \times (w_p \cdot P_t/P_{ref} + w_e \cdot E_t/E_{ref} + w_a \cdot A_t/A_{ref})$$

donde:

P_t = pozos fracturados en mes t (fuente: Adjunto IV)
 E_t = etapas de fractura en mes t (fuente: Adjunto IV)
 A_t = toneladas de arena bombeada en mes t (fuente: Adjunto IV)
 $P_{ref}, E_{ref}, A_{ref}$ = promedio mensual 2017-2019 (base 100)
 w_p, w_e, w_a = pesos (calibrados, ver 7.1.1)

7.1.1 CALIBRACIÓN DE PESOS

La versión inicial asigna pesos 40/35/25 por criterio experto. La calibración formal se realiza por **regresión contra el empleo sectorial registrado** (CIU 0910 - Servicios de apoyo al upstream) con rezago de 3-6 meses, buscando minimizar el error cuadrático:

$$\arg \min_{(w_p, w_e, w_a)} ||\text{Empleo}_{\{t+k\}} - IAP_t(w)||^2$$

sujeeto a $w_p + w_e + w_a = 1, w_i \geq 0$

La publicación pública documenta los pesos resultantes y su intervalo de confianza.

7.2 Modelos predictivos

El forecast se construye como un **ensamble ponderado** de tres modelos complementarios:

1. **SARIMAX(1,1,1)(1,0,1,12)** con variables exógenas: TC mayorista, IPC mensual, guidance CAPEX publicada. Captura estacionalidad y tendencia.
2. **Prophet**: maneja cambios de régimen con holiday-like events (planes gubernamentales: Plan Gas.Ar).
3. **XGBoost** con features lagged (rig count, WTI, DUCs): captura no-linealidades.

Los pesos del ensamble se calibran por **walk-forward validation** con ventanas móviles de 6 meses, minimizando MAPE combinado.

7.2.1 ESCENARIOS

- **Base:** pronóstico puntual del ensamble.
- **Optimista:** límite superior del intervalo de confianza 80%.
- **Pesimista:** límite inferior del intervalo de confianza 80%.

7.2.2 MÉTRICAS PUBLICADAS

Cada reporte mensual documenta transparentemente: **MAPE** (rolling 12m), **RMSE**, intervalo de confianza del ensamble, estabilidad de los pesos. Un MAPE alto no se esconde: se explica como característica del sector, no como falla del modelo.

7.3 Simulador de impacto paritario

Herramienta web interactiva para usar en la mesa paritaria. La operadora elige una propuesta salarial (ej: +15% trimestral escalonado), el simulador calcula en vivo:

- Costo laboral anualizado por perfil de empresa (usando distribuciones de plantilla típica por segmento de socios CEIPA).
- Comparativo vs. evolución de tarifas de servicios reales.
- Compresión de márgenes y punto de equilibrio.
- Benchmark vs. paritaria de Petroleros Privados en otras cuencas.

La fuente de datos salarial es el texto completo del CCT 644/12 parseado automáticamente desde Boletín Oficial.

7.4 Benchmarking con privacidad diferencial

La capa privada permite a cada socio cargar sus datos (facturación mensual, días de cobro, dotación, siniestralidad) y ver su posición relativa al sector sin exponer datos individuales. La política es:

- **Celdas con $N < 5$ se suprimen** (no se muestra cuartil).
- **Ruido Laplaciano calibrado** en estadísticos agregados con parámetro ϵ documentado públicamente.
- **Política de retención:** datos crudos por empresa se borran tras 12 meses; solo persisten los agregados anonimizados.
- **Auditoría:** cualquier socio puede solicitar en cualquier momento la eliminación de sus datos.

08 Capa de presentación

Un sistema de diseño coherente y un dashboard con 13 secciones entregan inteligencia accionable en un lenguaje visual editorial.

8.1 Principios de diseño

- **Editorial sobre ejecutivo:** privilegio la densidad informativa de un diario financiero (FT / The Economist) por sobre el "tablero con semáforos". El usuario es un profesional que sabe leer.
- **Un único acento cromático** (burgundy) usado con disciplina — nunca como relleno decorativo, siempre como jerarquía.
- **Tipografía trabajando:** titulares en IBM Plex Sans Condensed (denso, industrial), cuerpos en Plex Serif (legibilidad larga), números en Plex Mono (alineación tabular).
- **Fondo blanco consistente:** charts sin card que "sobredestaquen"; los datos fluyen con el texto.
- **Jerarquía por reglas horizontales**, no por sombras ni bordes. Feel de broadsheet, no de SaaS.

8.2 Sistema de componentes

COMPONENTE	USO
hero()	Masthead al tope de la sección — fecha, título, deck, chips de contexto
section_header()	Eyebrow small-caps + título serif + subtítulo descriptivo
stat_card()	Card con label, valor grande, delta opcional y sparkline SVG
bento_grid()	Grid tipográfico asimétrico sin bordes
chip()	Tag minimal para categorías — small caps con underline
csv_button()	Botón de export por sección
pdf_report_button()	Genera el reporte mensual on-demand

8.3 Mapa de secciones

#	SECCIÓN	PROPÓSITO
01	Resumen ejecutivo	Snapshot diario: IAP, pozos, producción, empleo, WTI, dólar
02	Actividad perforación y fractura	Series mensuales de etapas, pozos, arena
03	Producción por empresa	Ranking top 20 por petróleo y gas, evolución temporal
04	Producción por cuenca / provincia	Comparativa geográfica de producción
05	Pipeline de proyectos (EIAs)	Estudios ambientales en carpeta — leading indicator
06	Mapa GIS	84.000+ pozos, yacimientos, sísmicas, permisos (deck.gl)
07	Trayectorias shale	Curva de aprendizaje VM: rama horizontal vs. año
08	Precios de gas	Por cuenca, contrato y segmento (distribuidora/GNC/industria/usina/export)
09	Precios internacionales	Brent, WTI, LNG Japan, coal Australia (World Bank)
10	Empleo y salarios	Series SSPM sector petrolero vs. otras ramas
11	Forecast IAP-CEIPA	Histórico + 3 escenarios a 12 meses + backtest
12	Macroeconomía y precios	Variables BCRA + INDEC (TC, tasas, reservas, IPC)
13	Catálogo de fuentes	Transparencia: todas las fuentes listadas con URL y frecuencia

8.4 Accesibilidad y performance

- **Performance:** first paint < 1.2s (fonts auto-optimizadas, CSS minificado).
- **Queries cacheadas** por 10 minutos (no recarga innecesaria del warehouse).
- **WCAG AA:** contraste $\geq 4.5:1$ en texto; foco visible en navegación.
- **Mobile:** layout responsivo básico; versión mobile-first planificada en fase 4.

09 Calidad, testing y observabilidad

Un proyecto de datos sin tests es una hipótesis no validada. Cuatro capas de calidad automatizadas sostienen la confianza operativa.

9.1 Suite de tests

CAPA	QUÉ VALIDA	FRECUENCIA
Conectividad	APIs públicas responden (BCRA, INDEC, WB, CKAN)	Diaria
Warehouse	19 tablas presentes, volúmenes mínimos, rangos de fecha, coherencia geográfica	Post-ingest
Schemas Pandera	Tipos y rangos de cada columna del mart (nulls, rangos, dominios categóricos)	Post-ingest
Modelos	Forecast devuelve 12 meses, 3 escenarios ordenados, MAPE en rango razonable	Post-forecast
UI	Las 13 secciones renderizan sin errores (Playwright smoke)	Pre-deploy

9.2 Observabilidad en producción

- **Logging estructurado** (JSON) de cada corrida de ingesta con latencia, filas descargadas, errores.
- **Alertas:**
 - Falla de ingesta > 24h → email al equipo técnico.
 - Schema drift detectado → email + Slack.
 - IAP-CEIPA cae > 20% MoM → email a Comisión Directiva.
- **Dashboard interno** (cronjob → página estática) con health-check de las 20+ fuentes.

9.3 CI/CD

```
# .github/workflows/daily.yml
on:
  schedule:
    - cron: '0 6 * * *'    # 6 AM UTC (3 AM AR)
  workflow_dispatch:

jobs:
  ingest-and-test:
    runs-on: ubuntu-latest
    steps:
      - uses: actions/checkout@v4
      - run: pip install -r requirements.txt
      - run: python -m src.ingest
      - run: pytest
      - run: rsync warehouse to production VPS
      - if: failure() → alerta a Slack
```

10 Seguridad y gobernanza

La confianza institucional que requiere CEIPA exige un tratamiento explícito de seguridad y de gobernanza de datos — más aún al habilitar la capa privada.

10.1 Seguridad técnica

- **HTTPS obligatorio** en toda la superficie pública (Let's Encrypt + renovación automática).
- **Autenticación** para la capa privada vía OAuth2 (Google Workspace o magic links por email).
- **RBAC** (Role-Based Access Control) con tres niveles: público, socio, admin.
- **Secretos en variables de entorno**, nunca en código. Gestión con `.env.vault` o equivalente.
- **Backups cifrados** del warehouse a S3 con rotación 90 días.
- **Dependencias auditadas** mensualmente con `pip-audit`.

10.2 Gobernanza de datos

Un documento de **Protocolo de Gobernanza** — a firmarse por la Comisión Directiva al inicio de la fase 2 — establece:

- **Responsable editorial** del Observatorio (persona física en CEIPA).
- **Proceso de publicación**: revisión antes de publicar indicadores que puedan tener impacto mediático.
- **Política de privacidad** para datos cargados por socios.
- **Política de retención**: 24m públicos, 12m privados por empresa.
- **Proceso de baja**: cualquier socio puede solicitar eliminación con 7 días hábiles.
- **Condiciones de uso** de las fuentes externas (especialmente World Bank).

10.3 Consideraciones legales

La Ley de Protección de Datos Personales (25.326) y la futura reforma (PL 2026) aplican a la capa privada. Se diseñará conforme a:

- Base legal del tratamiento: consentimiento expreso del socio al registrarse.
- Minimización: solo se pide lo necesario para el benchmark.
- Portabilidad: export de datos propios a CSV/JSON en cualquier momento.
- Derecho de supresión operativo y automatizado.

11 Cronograma y entregables

Seis meses calendario, cinco fases con milestones verificables y un entregable tangible cada mes.

11.1 Visión general




FIG. 2 Cronograma de fases. Las barras se solapan porque cada fase arranca antes de que la anterior termine. Los milestones son verificables por la Comisión Directiva.

11.2 Fase 0 — Discovery (mes 1, primeras 4 semanas)

- Entrevistas a 15-20 empresas socias segmentadas por tipo (servicios especiales, logística, metalúrgicas, catering).
- Taller con Comisión Directiva: qué se publica (posicionamiento institucional) vs. qué queda interno (benchmarking privado).
- Validación del catálogo de indicadores priorizados.

Entregable: Documento de alcance + matriz de gobernanza + catálogo de KPIs.

11.3 Fase 1 — Ingesta + Warehouse (mes 1-2)

- Implementación del catálogo de fuentes.
- Pipeline de ingesta con validación Pandera.
- Warehouse DuckDB con marts principales.
- Suite de tests base y CI.

Entregable: Warehouse reproducible + 90% de las fuentes integradas + repo con tests.

11.4 Fase 2 – Observatorio público (mes 2-4)

- Dashboard Streamlit con 13 secciones.
- Sistema de diseño editorial aplicado.
- Índice IAP-CEIPA publicado.
- Export CSV por sección + reporte mensual PDF.

Entregable: Observatorio público live en `observatorio.ceipa.com.ar` .

11.5 Fase 3 – Modelos predictivos + GIS (mes 3-5)

- Forecast ensemble (SARIMAX + Prophet + XGBoost).
- Backtest walk-forward documentado.
- Mapa GIS interactivo con 5 capas (pozos, yacimientos, fracturas, sísmicas, permisos).
- Trayectorias shale con análisis de curva de aprendizaje.

Entregable: Módulo predictivo con MAPE < 25% en el promedio trimestral.

11.6 Fase 4 – Capa privada (mes 4-6)

- Autenticación OAuth2 + RBAC.
- Módulo de carga de datos privados por socio.
- Benchmarking anónimo con privacidad diferencial.
- Política de gobernanza firmada.

Entregable: Capa privada operativa con ≥ 5 empresas socias piloto.

11.7 Fase 5 – Simulador paritario + roll-out (mes 5-6)

- Parser automatizado de CCT 644/12 desde Boletín Oficial.
- Simulador interactivo de escenarios paritarios.
- Capacitación a referentes técnicos de 3 empresas socias.
- Documentación de traspaso y plan de sostenibilidad 24 meses.

Entregable: Simulador paritario usable en mesa + traspaso completo.

12 Esfuerzo, equipo y sostenibilidad

Estimación honesta de capacidad y un plan explícito para que el Observatorio sobreviva al equipo original.

12.1 Equipo propuesto

ROL	DEDICACIÓN	RESPONSABILIDADES
Tech Lead / Data Engineer	80% · 6m	Arquitectura, ingesta, marts, tests, deploy
Analista sectorial (ciencias sociales)	50% · 6m	Validación metodológica, entrevistas con socios, interpretación
Frontend / Data Viz	40% · 4m (fase 2-3)	Dashboard, sistema de diseño, UX
Data Scientist	30% · 3m (fase 3)	Modelos predictivos, benchmarking, metodología IAP
Project Manager	20% · 6m	Coordinación con CEIPA, gobernanza, comunicación

12.2 Esfuerzo estimado

Total: ~1.100 horas-persona en 6 meses calendario. Distribución aproximada:

- Fase 0 (Discovery): 80 h
- Fase 1 (Ingesta): 220 h
- Fase 2 (Observatorio público): 320 h
- Fase 3 (Predictivos + GIS): 240 h
- Fase 4 (Privada): 160 h
- Fase 5 (Simulador + traspaso): 80 h

12.3 Infraestructura

CONCEPTO	COSTO MENSUAL	NOTAS
VPS producción (4 vCPU · 8 GB)	USD 30	Hetzner Cloud
Backups S3 + CDN	USD 15	AWS S3 + Cloudflare Free
Dominio + SSL	USD 2	Namecheap + Let's Encrypt
Email transaccional (alertas)	USD 10	Postmark / SendGrid
Total infra	USD 57/mes	

12.4 Sostenibilidad post-proyecto

El Observatorio está diseñado para sobrevivir con **1 analista part-time (20h/mes)** una vez finalizada la construcción. Esto es posible porque:

- Pipeline 100% automatizado, sin intervención manual rutinaria.
- Tests automatizados detectan drift de fuentes.
- Stack open-source estándar sin componentes exóticos.
- Documentación exhaustiva del código, metodología y operación.
- Transferencia de know-how progresiva durante los 6 meses, no al final.

Se recomienda reservar presupuesto anual para *evolución* (nuevas fuentes, mejoras metodológicas, integraciones adicionales): ~10-15% del costo original.

13 Riesgos y mitigación

Identificamos riesgos en cinco dimensiones. Para cada uno, una estrategia concreta de mitigación.

RIESGO	PROBABILIDAD	IMPACTO	MITIGACIÓN
Sec. Energía discontinúa / cambia formato	Media	Alto	Schema drift detection automático; snapshots mensuales del warehouse; plan de fallback con scraping de informes PDF alternativos
Baja adopción de socios en la capa privada	Alta	Alto	Empezar con solo datos públicos; piloto con 3-5 socios antes de roll-out; benchmarking entrega valor tangible desde la primera carga
Sesgo de YPF (~50% producción)	Cierta	Medio	Paneles separados YPF vs. Resto-operadoras; IAP-CEIPA solo usa fracturas (más distribuidas entre empresas de servicio)
Politización del Observatorio	Media	Alto	Protocolo editorial firmado; metodología pública; publicación de incertidumbre (MAPE, intervalos); comunicación basada en hechos
MAPE alto que cuestione credibilidad	Media	Medio	Transparencia del error; publicar trimestre promedio (no mensual); comparar con MAPE de analistas comerciales privados
Capacidad técnica para sostenerlo	Media	Alto	Stack simple (Python + DuckDB + Streamlit); documentación exhaustiva; transferencia progresiva; contrato de mantenimiento opcional
Incidente de privacidad en capa privada	Baja	Muy alto	Diseño conforme a Ley 25.326; privacidad diferencial con $N \geq 5$; auditoría externa previa al roll-out; seguro de ciberseguridad
Construir algo técnicamente bello que nadie usa	Media	Muy alto	Fase 0 obligatoria con 15-20 entrevistas; validación de cada fase con 3-5 socios antes de avanzar; métricas de adopción como KPI del proyecto

El riesgo más alto no es técnico: es construir algo que nadie use. Por eso la Fase 0 no es negociable, y por eso cada fase subsiguiente incluye validación cualitativa con socios antes del commit.

14 Conclusión

Una propuesta sobria, con alcance acotado, métodos transparentes y sostenibilidad como restricción de diseño.

El Observatorio CEIPA no es un tablero: es una **infraestructura de inteligencia sectorial**. La diferencia es sustantiva. Un tablero es un proyecto; una infraestructura es un activo. Al finalizar las cinco fases, CEIPA dispondrá de:

- Una plataforma reproducible que consolida 20+ fuentes oficiales y entrega indicadores mensuales auditables.
- Un índice propio — IAP-CEIPA — con metodología publicada y defendible ante cualquier auditor, periodista u operadora.
- Una capa de benchmarking privado que entrega valor recurrente a cada socio y justifica su adhesión a la Cámara.
- Un simulador paritario utilizable en tiempo real en la mesa de negociación con el sindicato Petroleros Privados.
- Posicionamiento institucional de CEIPA como *la fuente autoritativa* de datos del sector proveedor de Vaca Muerta.

La propuesta es **deliberadamente conservadora** en tecnología y deliberadamente ambiciosa en alcance metodológico. El riesgo de usar un stack sofisticado (Spark, Kubernetes, arquitectura micro-servicios) sería romper la restricción de sostenibilidad. El riesgo de no intentar el simulador paritario o el benchmarking sería construir algo técnicamente sólido pero institucionalmente intrascendente.

Quedamos a disposición para ampliar cualquier sección, adaptar el cronograma y los esfuerzos a las prioridades específicas de CEIPA, y revisar la propuesta con la Comisión Directiva y socios piloto.

Documento: Propuesta Técnica — Observatorio CEIPA

Emisor: Equipo proponente

Destinatario: Comisión Directiva, CEIPA

Fecha: 20 de abril de 2026